

ỦY BAN NHÂN DÂN TP HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC SÀI GÒN
KHOA CÔNG NGHỆ THÔNG TIN



DỰ ĐOÁN DOANH THU PHÒNG VÉ PHIM

Thành viên nhóm: Nguyễn Xuân Hiếu - 3121410196

Nguyễn Ngọc Trường Chinh - 3119410046

Vũ Mạnh Đạt - 3123410074

Ngô Kim Thạch - 3121410446

Thông tin môn học: Phương pháp nghiên cứu khoa học
trong CNTT

Giảng viên hướng dẫn: TS. Đỗ Như Tài

TP. Hồ Chí Minh, 17 tháng 05 năm 2025

1. Tổng quan.....	3
1.1 Lý do chọn đề tài.....	3
1.2 Vấn đề nghiên cứu.....	4
1.3. Mục tiêu nghiên cứu.....	4
1.4. Câu hỏi nghiên cứu.....	4
1.5. Phạm vi nghiên cứu.....	5
2. Lược khảo tài liệu.....	5
3. Phương pháp nghiên cứu.....	7
4. Thực nghiệm.....	7
4.1 Tiền xử lý dữ liệu.....	7
4.2 Phân tích dữ liệu khám phá - EDA.....	10
4.3 Huấn luyện mô hình.....	14
4.3.1 Phương pháp huấn luyện mô hình.....	14
2. Các Chỉ Số Đánh Giá Mô Hình.....	15
4.3.2 Kết quả thực nghiệm.....	16
4. Kết luận.....	19
Tài liệu tham khảo (APA).....	22

Lời cảm ơn

Trong suốt quá trình thực hiện đề tài nghiên cứu này, tôi xin chân thành cảm ơn **Tiến sĩ Đỗ Như Tài**, người đã dành thời gian và công sức để hướng dẫn và hỗ trợ tôi hoàn thành bài tiểu luận. Với sự kiến thức sâu rộng, tận tâm và hỗ trợ quý báu của thầy, tôi đã có thể hoàn thành nghiên cứu này một cách tốt nhất có thể. Những góp ý và chỉ dẫn của thầy đã giúp tôi không chỉ hoàn thiện kỹ năng nghiên cứu mà còn nâng cao khả năng tư duy độc lập trong lĩnh vực học máy và phân tích dữ liệu.

Một lần nữa, tôi xin gửi lời cảm ơn sâu sắc tới thầy Tài vì sự tận tình và hỗ trợ trong suốt quá trình thực hiện nghiên cứu.

This image shows a single page of white paper with horizontal ruling lines. The lines are evenly spaced and run across the width of the page. There are no margins, text, or other markings on the paper.

DỰ ĐOÁN DOANH THU PHÒNG VÉ & HÀNH VI KHÁCH HÀNG

Tóm tắt:

Nghiên cứu này ứng dụng học máy để dự đoán doanh thu phòng vé dựa trên hành vi khách hàng. Bằng cách phân tích các đặc trưng của phim như ngân sách sản xuất, thể loại, thời lượng, độ phổ biến, cùng với thông tin về đạo diễn và dàn diễn viên. Dữ liệu được trích xuất từ TMDB 5000 Movie Dataset, một tập dữ liệu giàu thông tin và đáng tin cậy cho bài toán phân tích doanh thu. Các thuật toán như Linear Regression, Random Forest được triển khai để đánh giá hiệu quả dự đoán và phân nhóm phim theo đặc điểm doanh thu.

I - Giới thiệu

1. Tổng quan

1.1 Lý do chọn đề tài

Ngành công nghiệp điện ảnh hiện nay đang đối mặt với sự cạnh tranh khốc liệt, nơi việc dự đoán chính xác doanh thu phòng vé có thể mang lại lợi thế chiến lược đáng kể cho các nhà sản xuất, nhà đầu tư và rạp chiếu phim. Trong bối cảnh đó, việc ứng dụng các phương pháp học máy để dự đoán doanh thu trước khi phim được phát hành trở nên ngày càng quan trọng.

Đề tài này tập trung vào việc xây dựng mô hình dự đoán doanh thu phòng vé dựa trên các đặc trưng định lượng và định tính của phim, bao gồm ngân sách sản xuất, thể loại, thời lượng, mức độ phổ biến, cũng như thông tin về đạo diễn và dàn diễn viên. Dữ liệu được sử dụng là TMDB 5000 Movie Dataset – một tập dữ liệu có cấu trúc rõ ràng, đa dạng và phù hợp cho các bài toán học máy.

Mục tiêu của nghiên cứu không chỉ là đánh giá khả năng dự đoán của các mô hình như Linear Regression, Random Forest hay GB, mà còn là khám phá các yếu tố có ảnh hưởng mạnh đến doanh thu, từ đó cung cấp góc nhìn hỗ trợ ra quyết định cho các bên liên quan trong ngành điện ảnh.

1.2 Vấn đề nghiên cứu

Vấn đề nghiên cứu chính mà bài viết này đặt ra là liệu các đặc trưng liên quan đến bản thân bộ phim – như ngân sách sản xuất, thể loại, thời lượng, mức độ phổ biến, tên tuổi đạo diễn và diễn viên – có thể được sử dụng để dự đoán chính xác doanh thu phòng vé hay không.

Việc hiểu rõ mối liên hệ giữa các yếu tố này với kết quả tài chính của bộ phim có thể giúp các nhà sản xuất, nhà đầu tư và các đơn vị phát hành đưa ra quyết định hiệu quả hơn trong quá trình lên kế hoạch sản xuất và phân phối.

1.3. Mục tiêu nghiên cứu

Mục tiêu thứ nhất, xây dựng các mô hình học máy nhằm dự đoán doanh thu phòng vé của phim dựa trên các đặc trưng liên quan đến nội dung và quá trình sản xuất, bao gồm ngân sách, thể loại, thời lượng, mức độ phổ biến, đạo diễn và dàn diễn viên.

Mục tiêu thứ hai, đánh giá và so sánh hiệu quả dự đoán của các mô hình học máy như Linear Regression, Random Forest,...

Mục tiêu thứ ba, xác định các yếu tố có ảnh hưởng mạnh đến doanh thu phòng vé, từ đó cung cấp thông tin hỗ trợ các bên liên quan trong việc ra quyết định sản xuất, phân phối và tiếp thị phim.

1.4. Câu hỏi nghiên cứu

- Những yếu tố nào liên quan đến đặc điểm của phim (như ngân sách, thể loại, thời lượng, đạo diễn, diễn viên, mức độ phổ biến) có ảnh hưởng lớn đến doanh thu phòng vé?
- Mô hình học máy nào (Linear Regression, Random Forest, K-Means...) cho hiệu quả tốt nhất trong việc dự đoán doanh thu phòng vé dựa trên dữ liệu phim?
- Liệu các đặc trưng sản xuất có thể được sử dụng độc lập để dự đoán doanh thu, hay cần kết hợp với các yếu tố khác (nếu có) để nâng cao độ chính xác?
- Mức độ chính xác của mô hình học máy có đủ để hỗ trợ các nhà sản xuất và đơn vị phát hành trong việc đưa ra quyết định kinh doanh liên quan đến phân phối và tiếp thị phim không?

1.5. Phạm vi nghiên cứu

Đối tượng nghiên cứu: Các bộ phim điện ảnh được phát hành trên thị trường quốc tế, với trọng tâm là các yếu tố thuộc về nội dung và sản xuất phim như ngân sách, thể loại, thời lượng, đạo diễn, diễn viên, mức độ phổ biến và ngày phát hành.

Dữ liệu: Sử dụng tập dữ liệu **TMDB 5000 Movie Dataset** từ nền tảng Kaggle. Tập dữ liệu này cung cấp thông tin chi tiết về hơn 5.000 bộ phim, bao gồm cả dữ liệu định lượng và định tính liên quan đến sản xuất và phân phối.

Không gian nghiên cứu: Dữ liệu phim phát hành từ 1916 đến 2017, nghiên cứu thực hiện 03/2025–05/2025.

Thời gian nghiên cứu: Từ tháng 3/2025 đến tháng 5/2025.

2. Lược khảo tài liệu

Trong nghiên cứu của Ibrahim SA et al (2020), đã chỉ ra những yếu tố tác động đến doanh thu phòng vé gồm tên tuổi của đạo diễn và diễn viên (20,6%), số lượng suất

chiếu (12.0%), đánh giá phim (10,3%), kinh phí (9,5%), mùa chiếu (5,2%), thời gian chiếu (5.2%). Trong nghiên cứu của Nikhil A et al (2011) cũng được thực nghiệm dựa trên một số đặc trưng như trên. Ngoài ra ông cũng cho rằng nên kết hợp phân tích thêm một số yếu tố khác để có thể đưa ra dự đoán dựa trên nhiều góc độ khác nhau.

Có thể dễ dàng nhận thấy, sở thích của khách hàng thường bị ảnh hưởng bởi rất nhiều yếu tố, bao gồm các yếu tố cá nhân, xã hội, tâm lý. Michael L et al (2015) đã nói sự thành bại của một bộ phim khi bước vào phòng vé sẽ phụ thuộc vào 3 yếu tố cơ bản: What - who - when. Việc tìm hiểu về thói quen của khách hàng là một điều cần thiết để tác động đến doanh thu của bộ phim khi công chiếu ở rạp.

Trong ngành điện ảnh trong nước, 10 năm vừa qua, doanh thu phim Việt chỉ chiếm khoảng từ 18-33%. Phim ngoại nhập khẩu đang thắng thế với tỷ lệ khoảng từ 67-82% tổng doanh thu phòng vé. Thống kê cho thấy thể loại phim phiêu lưu và hành động đang thống trị phòng vé, chiếm thị phần khổng lồ là 25,41% và 22,84%. Dễ hiểu vì theo đánh giá chủ quan, tệp khách hàng của thể loại phim này đa số sẽ là giới trẻ hoặc trung niên, năng lực tài chính ổn định và có nhu cầu giải trí cao. Những phim thuộc thể loại chính kịch hoặc thời sự chính trị lại cho ra kết quả khá thấp.

Tuy nhiên, nguyên nhân thật sự dẫn đến việc doanh thu phòng vé ở Việt Nam không phát triển mạnh không chỉ do thể loại phim dựa trên sở thích của người tiêu dùng mà còn là các yếu tố dựa trên thói quen xem phim của người tiêu dùng.

Theo **Box Office Vietnam**, một yếu tố lớn tác động đến nhu cầu xem phim ở rạp của người tiêu dùng chính là thói quen sinh hoạt hằng ngày. Theo như các chuyên gia phân tích, nhiều người ngại ra rạp xem phim sẽ phụ thuộc vào các yếu tố: sự tiện lợi ở rạp chiếu phim (có thể là ghế ngồi, âm thanh, vị trí ngồi so với màn hình), giá cả, số lượng suất chiếu, khung giờ,... Thậm chí sở thích xem phim một mình hoặc xem phim với bạn bè cũng ảnh hưởng đến quyết định ra rạp của một số người. Giá vé và các chương trình khuyến mãi cũng ảnh hưởng đến sự lựa chọn của khách hàng. Những khách hàng có ngân sách hạn chế có thể chọn xem những bộ phim có mức giá vé hợp lý hơn hoặc những bộ phim được giảm giá, ưu đãi đặc biệt.

Những nghiên cứu của Nikhil A et al (2011), Michael L et al (2015), Ibrahim SA et al (2020) đã chỉ ra được rất nhiều yếu tố tác động đến doanh thu phòng vé nhờ vào ứng dụng rất nhiều mô hình học máy chuyên sâu. Việc áp dụng các mô hình học máy tiên tiến như Random Forest và hồi quy tuyến tính giúp tối ưu hóa độ chính xác trong dự đoán doanh thu, và những mô hình này đã chứng minh được hiệu quả khi dựa vào dữ liệu lịch sử của các bộ phim. **Tuy nhiên**, các mô hình hiện tại chủ yếu dựa trên các yếu tố sản xuất và phân phối phim để tìm ra sở thích của khách hàng, vẫn chưa phân tích những nguyên do góp phần khiến bộ phim không dành được đông đảo khách hàng chọn lựa..

Dựa trên những phân tích phía trên, có thể xây dựng **khung lý thuyết** tổng quát cho đề tài nghiên cứu như sau:

Khung lý thuyết cho nghiên cứu này sẽ dựa trên các lý thuyết về hành vi người tiêu dùng trong lĩnh vực giải trí và học máy. Một trong những lý thuyết quan trọng có thể áp dụng là Lý thuyết Hành vi Người tiêu dùng (Consumer Behavior Theory), đặc biệt là trong việc phân tích các yếu tố tác động đến quyết định mua hàng của khách hàng. Khung lý thuyết thứ hai là về việc áp dụng các mô hình học máy cho việc phân tích và dự đoán hành vi người tiêu dùng. Các mô hình học máy như hồi quy tuyến tính, Random Forest, ... sẽ được sử dụng để xây dựng mô hình dự đoán khả năng mua vé lại của khách hàng và ước tính doanh thu phòng vé. Khung lý thuyết này sẽ giúp xác định các yếu tố hành vi quan trọng nhất mà mô hình có thể học và sử dụng để đưa ra các dự đoán.

Từ khung lý thuyết này, nghiên cứu sẽ kế thừa các phương pháp học máy đã được áp dụng trong các nghiên cứu trước, kết hợp đánh giá hiệu năng của 4 mô hình (Ridge, RF, GB, LightGBM) và sử dụng SHAP để diễn giải kết quả, cung cấp góc nhìn minh bạch cho nhà làm phim và nhà đầu tư.

II - Nghiên cứu

3. Phương pháp nghiên cứu

Thiết kế nghiên cứu: Định lượng - thu thập dữ liệu trên kaggle, sử dụng các thước đo thống kê (mean, median, RMSE) và mô hình hóa toán học (hồi quy, cây quyết định, ...) để đánh giá.

Đối tượng và mẫu nghiên cứu: Toàn bộ 4823 phim sau khi loại đi 1427 phim không có thống kê doanh thu.

Cách thu thập dữ liệu:

- Dữ liệu thô được tải về từ Kaggle: `tmdb_5000_movies.csv` và `tmdb_5000_credits.csv`.
- Merge hai file dựa trên khóa id → DataFrame kết hợp chứa metadata, cast, crew.
- Xử lý JSON (sử dụng `ast.literal_eval`) để trích xuất danh sách genres, cast, crew.
- Quy trình không sử dụng bảng hỏi, phỏng vấn hay quan sát trực tiếp.

Công cụ sử dụng phân tích và huấn luyện dữ liệu:

Ngôn ngữ & môi trường: Python (Google Colab, Jupiter Notebook).

Thư viện xử lý: pandas, numpy để làm sạch, chuyển đổi dữ liệu, kết hợp thêm nhiều thư viện để trực quan hóa dữ liệu.

4. Thực nghiệm

4.1 Tiền xử lý dữ liệu

Nạp `tmdb_5000_movies.csv` và `tmdb_5000_credits.csv`, merge hai dataset lại thành một để dễ dàng phân tích.

Bộ dữ liệu TMDB gồm ban đầu khoảng **5.000** phim, sau khi loại bỏ **1.427** phim thiếu Revenue (gán cờ Rev_missing), còn **4.823** phim để xây dựng mô hình. Tiến hành xử lý JSON, trích xuất Director và top 5 dàn cast của phim.

Các đặc trưng chính:

- **id, title**: Mã và tên phim.
- **release_date, release_year, release_month, release_quarter, is_holiday**: Thông tin ngày phát hành.
- **budget, log_budget**: Ngân sách sản xuất và log-transform.
- **revenue, log_revenue**: Doanh thu và log-transform.
- **popularity, runtime, vote_average, vote_count**: Các chỉ số đánh giá và thời lượng phim.
- **genres_list, num_genres, primary_genre, genre_***: Thẻ loại phim (multi-hot và primary).
- **director, cast_1 ... cast_5**: Đạo diễn và top-5 diễn viên.
- **star_power**: Doanh thu trung bình lịch sử của diễn viên chính.
- **num_cast, num_crew**: Số lượng diễn viên và nhân sự.
- **rev_missing**: Cờ đánh dấu phim thiếu doanh thu.

Phân tích phân phối ban đầu của hai đặc trưng là ngân sách và doanh thu.

	Column	Min	Q1	Median	Mean	Q3	Max	Skewness	Kurtosis	Outliers (IQR)
0	budget	0	790000.0	15000000.0	29045039.88	40000000.0	380000000	2.44	10.65	321
1	revenue	0	0.0	19170001.0	82260638.65	92917187.0	2787965087	4.44	36.09	472

hình 4.1.1 Bảng mô tả dữ liệu gốc

Đo độ bất đối xứng của phân phối so với phân phối chuẩn. Skewness > 0 nghĩa là đuôi phải dài hơn (nhiều giá trị lớn), skewness < 0 nghĩa là đuôi trái dày hơn (nhiều giá trị nhỏ). Giá trị skewness cao báo hiệu phân phối có nhiều outlier hoặc nghiêng về một phía. Có thể dễ dàng thấy giá trị Skewness khá cao, cả Budget và Revenue đều cho thấy phân phối lệch phải mạnh.

Đo độ dày của đuôi và độ nhọn của đỉnh phân phối. Kurtosis > 3 (quá chuẩn) nghĩa là phân phối có đỉnh nhọn và đuôi dày (nhiều outlier hai bên); kurtosis < 3 nghĩa là phân phối bẹt hơn, ít outlier. Ở đây, hai giá trị đo được đều cho thấy phân phối có đỉnh nhọn và đuôi dày, hậu quả đi kèm là có nhiều outlier xuất hiện.

Phân phối lệch (high skewness) khiến các mô hình tuyến tính và đánh giá trung bình bị ảnh hưởng vì mất cân đối dữ liệu. Kurtosis cao đi kèm đuôi dày nghĩa là nhiều outliers, có thể làm tăng sai số RMSE/MAPE.

Với phân phối như trên, mô hình hồi quy hoặc tree-based dễ bị chi phối bởi nhóm giá

trị rất nhỏ (0) và các outliers cực lớn. Cần chuẩn hóa phân phối trước khi mô hình hóa. Vì vậy, đề xuất áp dụng kỹ thuật biến đổi Logarit, **Log-transform**, lên hai biến đặc trưng Budget và Revenue để:

- **Giảm độ lệch phân phối (Skewness)** bằng cách nén các dải giá trị lớn gần với giá trị nhỏ.
- **Hạn chế ảnh hưởng của outliers**, giúp mô hình học máy không bị chi phối bởi giá trị quá lớn.
- Xử lý giá trị 0 an toàn.

Sau Log-Transform, giá trị của hai biến đặc trưng mới đã có sự thay đổi.

	Column	Min	Q1	Median	Mean	Q3	Max	Skewness	Kurtosis	Outliers (IQR)
0	log_budget	0.0	13.58	16.52	13.00	17.50	19.76	-1.22	2.65	1069
1	log_revenue	0.0	0.00	16.77	12.22	18.35	21.75	-0.76	1.70	0

hình 4.1.2 Bảng mô tả dữ liệu sau khi Log-transform


Một số đặc trưng thể hiện dưới dạng JSON, như dàn cast, thể loại phim, crew. Những đặc trưng này cần được xử lý JSON, chọn trích xuất đạo diễn, top 5 diễn viên nổi trội của phim.

Sau khi kiểm tra dữ liệu thiếu, nhận ra không có quá nhiều ảnh hưởng (Missing <5%), không nhất thiết phải sàng lọc lại dữ liệu.

	Missing (#)	Missing (%)
cast_5	169	3.5
cast_4	93	1.9
cast_3	63	1.3
cast_2	53	1.1
cast_1	43	0.9
director	30	0.6

hình 4.1.3 Bảng mô tả dữ liệu thiếu


4.2 Phân tích dữ liệu khám phá - EDA



hình 4.2.1 Biểu đồ phân phối doanh thu

Biểu đồ cho thấy phần lớn các giá trị của $\log_{1p}(\text{Revenue})$ tập trung gần 0, với một số lượng lớn phim có doanh thu gần bằng 0 (doanh thu thấp hoặc không có doanh thu). Đây là điều hiển nhiên vì nhiều bộ phim có doanh thu thấp hoặc không đạt được gì (hoặc do thiếu dữ liệu doanh thu).

Phân phối còn lại có đuôi dài về phía phải, nơi có một số ít phim có doanh thu rất lớn. Khoảng 1.400 phim có $\log_{1p}(\text{Revenue})$ rất gần 0, có thể là phim không có doanh thu hoặc rất ít doanh thu (có thể phải xử lý giá trị thiếu hoặc đưa vào cờ đánh dấu `rev_missing`).



hình 4.2.2 Biểu đồ scatter plot giữa $\log(\text{budget})$ và $\log(\text{revenue})$


Phần lớn các điểm dữ liệu tập trung gần phía dưới, nơi budget thấp ($\log(\text{Budget}) \approx 0-3$) và doanh thu thấp ($\log(\text{Revenue}) \approx 0-5$). Đây là nhóm các phim có ngân sách khiêm tốn và doanh thu thấp hoặc không có doanh thu.

Các điểm ở phía trên thể hiện mối quan hệ giữa budget và revenue: với budget cao, revenue cũng có xu hướng tăng mạnh. Tuy nhiên, mối quan hệ không hoàn toàn tuyến tính mà hơi phân tán, thể hiện rằng ngoài ngân sách, các yếu tố khác cũng tác động đến doanh thu (như thể loại, dàn diễn viên, thời gian phát hành).

Mối quan hệ giữa ngân sách và doanh thu có xu hướng tăng trưởng theo chiều ngang, nhưng sự phân tán và các outliers cho thấy mô hình sẽ cần phải học cách xử lý các giá trị bất thường và đưa ra các dự đoán chính xác hơn cho những phim có ngân sách thấp hoặc rất cao.

Để mô hình học tốt hơn, chúng ta cần chú trọng vào việc xử lý outliers và log-transform đã giúp giảm thiểu sự chênh lệch này.

Biểu đồ này cho thấy Top 10 đạo diễn có doanh thu trung bình cao nhất, với Joss Whedon đứng đầu với doanh thu trung bình 1.4 tỷ USD. Các đạo diễn khác trong top 10 như Chris Buck, Kyle Balda, Lee Unkrich cũng có doanh thu trung bình rất cao, trên 1 tỷ USD.




hình 4.2.3 Biểu đồ top 10 đạo diễn - trung bình doanh thu

Danh tiếng của đạo diễn có thể giúp khán giả dễ dàng lựa chọn phim dựa trên tác phẩm trước đó của họ.

Những đạo diễn nổi tiếng như Joss Whedon, Peter Jackson và Chris Buck thường dẫn đầu về doanh thu, điều này cũng có thể giúp các nhà đầu tư quyết định xem liệu họ có nên đầu tư vào các dự án của những đạo diễn này.


Biểu đồ cho thấy rằng phim có star power thấp (doanh thu trung bình của diễn viên chính thấp) sẽ có doanh thu phòng vé thấp hoặc không đáng kể.



hình 4.2.4 Biểu đồ Star Power of Lead Actor vs Box-Office

Star power của diễn viên chính có ảnh hưởng mạnh mẽ đến doanh thu phòng vé, và diễn viên nổi tiếng có thể đóng vai trò quan trọng trong việc thu hút người xem, đặc biệt là trong các bộ phim có ngân sách lớn.


Biểu đồ cũng cho thấy rằng mô hình học máy có thể được cải thiện bằng cách xem xét star power của diễn viên chính khi dự đoán doanh thu phòng vé.



hình 4.2.5 Biểu đồ boxplot $\log(\text{Revenue})$ theo Tháng phát hành

Tháng phát hành ảnh hưởng rõ rệt đến doanh thu phòng vé. Các tháng có xu hướng phát hành phim lớn như tháng 12, tháng 1, tháng 5 có doanh thu tốt hơn.

Chiến lược phát hành phim có thể được cải thiện bằng cách chọn các tháng phát hành thích hợp hơn, đồng thời giảm thiểu rủi ro của các tháng có mức doanh thu thấp hoặc không ổn định.



hình 4.2.6 Biểu đồ Correlation Heatmap (Numeric)

Log-budget và Log-revenue có mối quan hệ rõ ràng và mạnh mẽ, vì ngân sách lớn hơn thường đồng nghĩa với doanh thu lớn hơn.

Các yếu tố như popularity, vote_count, và vote_average cũng có tác động quan trọng đến doanh thu phòng vé, nhưng không mạnh mẽ như ngân sách.

Mối quan hệ giữa các biến như số lượng diễn viên và nhân viên không quá rõ ràng với doanh thu.

Sử dụng các mối tương quan này để cải thiện các mô hình học máy, xác định các biến quan trọng nhất ảnh hưởng đến doanh thu.

4.3 Huấn luyện mô hình

4.3.1 Phương pháp huấn luyện mô hình

Trong nghiên cứu này, chúng ta sử dụng các mô hình học máy để dự đoán **doanh thu phòng vé** của các bộ phim. Các mô hình học máy được áp dụng bao gồm:

4.3.1.1 XGBoost (Extreme Gradient Boosting)

XGBoost (Extreme Gradient Boosting) là một thuật toán boosting rất mạnh và phổ biến trong học máy, đặc biệt là trong các bài toán dự đoán. XGBoost là một phiên bản mở rộng và tối ưu của Gradient Boosting (GB), với nhiều cải tiến về tốc độ, khả năng xử lý dữ liệu lớn và khả năng chống overfitting.

- **Cách hoạt động của XGBoost:**

XGBoost thuộc vào nhóm Gradient Boosting, tức là mô hình học máy boosting được huấn luyện theo phương pháp học tuần tự. Cụ thể, mỗi cây quyết định mới sẽ học cách sửa lỗi của các cây trước đó.

1. Khởi tạo mô hình với một giá trị dự đoán ban đầu (thường là giá trị trung bình của biến mục tiêu đối với bài toán hồi quy).

2. Lặp lại các bước:

- Tính residuals (lỗi) từ dự đoán trước đó, tức là phần còn lại mà mô hình chưa dự đoán chính xác.
- Huấn luyện một cây quyết định nhỏ (weak learner) để dự đoán lỗi (residuals).
- Cập nhật dự đoán của mô hình bằng cách cộng thêm một tỷ lệ phần trăm của kết quả cây quyết định mới vào dự đoán tổng thể.
- Lặp lại quá trình này cho đến khi mô hình đạt độ chính xác mong muốn hoặc số lượng cây đạt ngưỡng.

- **Ưu điểm của XGBoost:**

- Hiệu suất cao: XGBoost có khả năng dự đoán chính xác ngay cả với dữ liệu phức tạp và không đồng nhất.
- Khả năng xử lý dữ liệu lớn: XGBoost có khả năng xử lý nhanh dữ liệu lớn nhờ vào khả năng tính toán song song và các cải tiến khác.
- Chống overfitting tốt: Nhờ vào regularization (L1, L2) và tree pruning, XGBoost giảm thiểu overfitting.
- Khả năng làm việc với dữ liệu thiếu: XGBoost xử lý dữ liệu thiếu tự động mà không cần phải điền giá trị thiếu.

- **Nhược điểm của XGBoost:**

- Cần điều chỉnh tham số: Để tối ưu mô hình, XGBoost yêu cầu tinh chỉnh các tham số khá kỹ lưỡng. Điều này có thể mất thời gian.
- Khó giải thích: XGBoost là một mô hình hộp đen, do đó rất khó để giải thích rõ ràng các quyết định mà mô hình đưa ra.
- Chi phí tính toán cao: XGBoost có thể yêu cầu nhiều bộ nhớ và tài nguyên tính toán khi làm việc với tập dữ liệu quá lớn.

4.3.1.2 RandomForestRegressor

RandomForestRegressor là một thuật toán học máy được sử dụng cho bài toán hồi quy (dự đoán giá trị liên tục), và là một biến thể của Random Forest.

Random Forest là một thuật toán học máy thuộc nhóm ensemble learning, trong đó kết hợp nhiều mô hình yếu (thường là các cây quyết định) để tạo ra một mô hình mạnh mẽ và chính xác hơn.

- **Cách hoạt động của RandomForestRegressor:**

1. **Bootstrap Aggregating (Bagging):**

- Bagging là một kỹ thuật trong đó chúng ta tạo nhiều mẫu con ngẫu nhiên từ tập dữ liệu huấn luyện gốc. Sau đó, một cây quyết định sẽ được huấn luyện trên mỗi mẫu con.
- Quá trình huấn luyện: Trong RandomForest, mỗi cây quyết định được huấn luyện với một mẫu con ngẫu nhiên của dữ liệu huấn luyện. Điều này giúp tăng tính độc lập giữa các cây và giảm thiểu overfitting.

2. **Chọn đặc trưng ngẫu nhiên:**

- Khi xây dựng mỗi cây quyết định, thay vì chọn tất cả các đặc trưng để chia nhánh, Random Forest chỉ chọn một danh sách con ngẫu nhiên của các đặc trưng. Điều này giúp làm giảm sự tương quan giữa các cây, làm tăng tính đa dạng và giảm overfitting.

3. **Dự đoán:**

- Sau khi huấn luyện xong, khi muốn dự đoán cho một điểm dữ liệu mới, RandomForestRegressor sẽ yêu cầu tất cả các cây trong rừng đưa ra dự đoán.

- **Ưu Điểm của RandomForestRegressor**

1. **Giảm overfitting:**

- Random Forest giúp giảm overfitting so với việc chỉ sử dụng một cây quyết định đơn lẻ. Nhờ vào việc sử dụng nhiều cây quyết định với các mẫu ngẫu nhiên và đặc trưng ngẫu nhiên, mô hình có thể tổng quát hóa tốt hơn.

2. **Khả năng làm việc với dữ liệu không đồng nhất:**

- Random Forest có thể làm việc với dữ liệu có nhiều dữ liệu thiếu, dữ liệu không đồng nhất (dữ liệu phân phối khác nhau), hoặc dữ liệu không tuyến tính.

3. **Tự động xử lý dữ liệu thiếu:**

- Khi có giá trị thiếu, RandomForestRegressor có thể tự động bỏ qua các giá trị thiếu trong quá trình huấn luyện mà không cần xử lý đặc biệt.

4. Khả năng mô hình hóa quan hệ phi tuyến:

- Random Forest có khả năng mô hình hóa các quan hệ phi tuyến giữa các đặc trưng và mục tiêu mà hồi quy tuyến tính không thể làm được.

5. Không yêu cầu chuẩn hóa dữ liệu:

- Do các cây quyết định không bị ảnh hưởng bởi thang đo của các đặc trưng, Random Forest không yêu cầu chuẩn hóa dữ liệu (ví dụ: Min-Max scaling, Standardization).

• Nhược Điểm của RandomForestRegressor

1. Không dễ giải thích:

- Một trong những nhược điểm lớn của RandomForestRegressor là khó giải thích. Vì mô hình sử dụng rất nhiều cây quyết định, việc giải thích kết quả của mô hình trở nên khó khăn và mô hình này được xem là một "hộp đen".

2. Yêu cầu tài nguyên tính toán cao:

- Khi tập dữ liệu lớn, việc huấn luyện Random Forest sẽ mất rất nhiều thời gian và tài nguyên tính toán vì phải xây dựng và lưu trữ một lượng lớn các cây quyết định.

3. Không phù hợp cho dữ liệu với số lượng đặc trưng cực lớn:

- Mặc dù Random Forest là mạnh mẽ trong việc xử lý dữ liệu với số lượng đặc trưng lớn, nhưng với dữ liệu cực kỳ lớn (với hàng nghìn hoặc hàng triệu đặc trưng), mô hình vẫn có thể gặp khó khăn về hiệu suất và tài nguyên tính toán.

4. Phức tạp với quá nhiều cây:

- Khi số lượng cây quyết định trong rừng quá lớn (hàng nghìn cây), Random Forest có thể trở nên rất chậm và khó kiểm soát.

5. Không phải là mô hình tốt nhất cho tất cả các bài toán:

- Mặc dù Random Forest là một mô hình mạnh mẽ, nhưng nó không phải lúc nào cũng là lựa chọn tốt nhất đối với tất cả các bài toán. Các mô hình khác như XGBoost hoặc LightGBM có thể vượt trội hơn trong một số trường hợp.

4.3.1.3 GradientBoostingRegressor

GradientBoostingRegressor là một thuật toán học máy mạnh mẽ dùng cho bài toán hồi quy (dự đoán giá trị liên tục), được xây dựng dựa trên phương pháp gradient boosting. Thuật toán này tạo ra một mô hình mạnh mẽ bằng cách tích lũy các cây quyết định yếu, với mỗi cây mới được huấn luyện để giảm thiểu sai số còn lại của mô hình.

- **Cách hoạt động của GradientBoostingRegressor**

1. **Khởi tạo mô hình với một giá trị dự đoán ban đầu:**

Mô hình bắt đầu bằng việc dự đoán một giá trị ban đầu, thường là giá trị trung bình của mục tiêu (đối với hồi quy).

2. **Lặp lại quá trình học:**

- Tính toán residuals (lỗi): Lỗi là sự khác biệt giữa giá trị thực tế và dự đoán của mô hình.
- Huấn luyện cây quyết định: Cây quyết định tiếp theo được huấn luyện để dự đoán residuals. Mỗi cây quyết định tiếp tục cải thiện những sai số mà mô hình đã gặp phải trước đó.
- Cập nhật mô hình: Sau khi huấn luyện cây quyết định, mô hình sẽ cập nhật dự đoán bằng cách cộng thêm một phần dự đoán của cây vào dự đoán trước đó.
- Lặp lại cho đến khi đạt ngưỡng: Quá trình này sẽ tiếp tục cho đến khi mô hình đạt được độ chính xác mong muốn hoặc số lượng cây được cố định.

3. **Tối ưu hóa với Gradient Descent:**

- Các cây quyết định trong Gradient Boosting được huấn luyện theo gradient descent, giúp tối ưu hóa hàm mất mát (loss function). Mỗi cây sẽ cố gắng giảm thiểu lỗi còn lại từ mô hình trước đó.

4. **Dự đoán cuối cùng:**

- Dự đoán cuối cùng của mô hình là tổng của dự đoán của tất cả các cây quyết định, với mỗi cây quyết định đóng góp vào kết quả chung.

- **Ưu điểm của GradientBoostingRegressor**

1. **Hiệu suất cao:**

- GradientBoostingRegressor có khả năng dự đoán rất chính xác và đã chứng minh hiệu quả vượt trội trong nhiều bài toán học máy. Thuật toán này có thể hoạt động tốt với dữ liệu không đồng nhất và không tuyến tính.

2. Khả năng làm việc với các đặc trưng phi tuyến:

- Gradient Boosting có khả năng mô hình hóa quan hệ phi tuyến giữa các đặc trưng và mục tiêu, điều này giúp mô hình dự đoán chính xác hơn.

3. Dễ dàng điều chỉnh tham số:

- Các tham số của mô hình như learning rate, số lượng cây, max_depth có thể được điều chỉnh để tối ưu hóa hiệu suất mô hình.

4. Khả năng chống overfitting:

- Mặc dù Gradient Boosting có thể dễ dàng bị overfitting nếu không được điều chỉnh tốt, nhưng với các tham số như learning rate và early stopping, mô hình có thể chống overfitting khá tốt.

5. Xử lý tốt với dữ liệu thiếu:

- Gradient Boosting có khả năng xử lý dữ liệu thiếu mà không cần phải điền giá trị thiếu.

● Nhược điểm của GradientBoostingRegressor

1. Chạy chậm và yêu cầu tài nguyên tính toán cao:

- Gradient Boosting là thuật toán huấn luyện tuần tự, nghĩa là mỗi cây quyết định được xây dựng dựa trên cây trước đó. Điều này dẫn đến việc huấn luyện sẽ mất thời gian, đặc biệt khi có số lượng lớn dữ liệu hoặc số lượng cây quá nhiều.
- Cùng với đó, yêu cầu tài nguyên tính toán cao (về bộ nhớ và CPU), đặc biệt khi số lượng cây rất lớn.

2. Dễ bị overfitting nếu không tinh chỉnh tham số:

- Mặc dù Gradient Boosting có khả năng học rất tốt từ dữ liệu, nhưng nếu không kiểm soát tham số, mô hình có thể dễ dàng bị overfitting, đặc biệt khi số lượng cây quyết định quá lớn và học quá sâu.
- Vì vậy, việc tinh chỉnh tham số rất quan trọng trong việc cải thiện độ chính xác và giảm overfitting.

3. Khó giải thích (hộp đen):

- Cũng như các mô hình học máy phức tạp khác, Gradient Boosting là một mô hình hộp đen, tức là rất khó để giải thích rõ ràng cách mà mô hình đưa ra quyết định dựa trên dữ liệu đầu vào.
- Mặc dù có thể sử dụng các kỹ thuật như SHAP hoặc feature importance để hiểu tác động của từng đặc trưng, nhưng việc giải thích chi tiết vẫn rất khó khăn.

4. Khó khăn trong việc xử lý dữ liệu không cân bằng:

- Nếu dữ liệu có phân phối không cân bằng (ví dụ: số lượng mẫu ít cho một số lớp), mô hình có thể gặp khó khăn trong việc học và dự đoán chính xác các giá trị từ lớp ít.

4.3.1.4 Ridge Regression

Ridge Regression là một thuật toán học máy thuộc nhóm hồi quy tuyến tính (Linear Regression), được sử dụng để giải quyết bài toán dự đoán giá trị liên tục. Tuy nhiên, Ridge Regression khác với hồi quy tuyến tính thông thường ở điểm nó có thêm một phần regularization (phạt), giúp giảm overfitting và điều chỉnh mô hình khi có quá nhiều đặc trưng (features).

- **Cách Hoạt Động của Ridge Regression**

1. **Hồi quy tuyến tính truyền thống:**

- Trong hồi quy tuyến tính, ta tìm các hệ số θ sao cho sai số giữa giá trị dự đoán và giá trị thực tế là nhỏ nhất, tức là tối thiểu hóa hàm chi phí Mean Squared Error (MSE):
- Mô hình tìm các giá trị của θ sao cho hàm chi phí này là nhỏ nhất.

2. **Regularization trong Ridge Regression:**

- Để giảm overfitting, Ridge Regression thêm một phần phạt vào hàm chi phí. Phần phạt này là tổng bình phương các hệ số θ , và mức độ phạt được điều chỉnh bởi tham số λ
- Tham số λ là một tham số điều chỉnh. Khi λ lớn, mô hình sẽ bị "phạt" nhiều hơn và hệ số θ sẽ bị nhỏ đi, giúp giảm độ phức tạp của mô hình. Nếu $\lambda = 0$, Ridge Regression trở thành hồi quy tuyến tính thông thường.

3. **Tìm hệ số tối ưu:**

- Ridge Regression sẽ tìm kiếm các hệ số θ sao cho hàm chi phí kết hợp giữa MSE và regularization term là nhỏ nhất:
- Hệ số θ sẽ được điều chỉnh sao cho hàm chi phí này được tối ưu, giúp mô hình tổng quát tốt hơn với dữ liệu chưa thấy.

- **Ưu Điểm của Ridge Regression**

1. **Giảm overfitting:**

- Ridge Regression giúp giảm overfitting (quá khớp với dữ liệu huấn luyện) bằng cách thêm phần regularization, hạn chế các hệ số quá lớn. Điều này giúp mô hình tổng quát tốt hơn khi gặp dữ liệu mới.

2. **Khả năng xử lý dữ liệu nhiễu:**

- Ridge Regression rất hiệu quả trong việc xử lý dữ liệu có nhiễu (noise) hoặc dữ liệu có nhiều đặc trưng không quan trọng. Vì regularization sẽ giúp mô hình không quá phụ thuộc vào các đặc trưng không quan trọng.

3. **Khả năng làm việc với nhiều đặc trưng:**

- Mô hình này có thể làm việc tốt với dữ liệu có số lượng đặc trưng rất lớn, kể cả khi số đặc trưng vượt quá số lượng mẫu (high-dimensional data). Điều này rất hữu ích trong các bài toán có nhiều đặc trưng, chẳng hạn như gene expression data trong nghiên cứu sinh học.
- 4. Không dễ bị ảnh hưởng bởi các đặc trưng có mối quan hệ tuyến tính:**
- Ridge Regression có thể xử lý tốt với các đặc trưng có mối quan hệ tuyến tính giữa chúng mà không làm giảm hiệu suất mô hình.
- **Nhược Điểm của Ridge Regression**
- 1. Không giải quyết được multicollinearity hoàn toàn:**
- Mặc dù regularization giúp giảm độ phức tạp của mô hình, nhưng nếu có quá nhiều multicollinearity (sự tương quan mạnh giữa các đặc trưng), mô hình vẫn có thể gặp phải vấn đề overfitting hoặc hiện tượng dư thừa đặc trưng.
- 2. Chỉ hoạt động tốt với mối quan hệ tuyến tính:**
- Ridge Regression là một mô hình hồi quy tuyến tính. Vì vậy, nếu dữ liệu có mối quan hệ phi tuyến, Ridge Regression có thể không hoạt động hiệu quả. Trong trường hợp này, có thể cần phải chuyển sang các mô hình phi tuyến như Random Forest, XGBoost, hoặc SVM.
- 3. Cần lựa chọn tham số λ :**
- Ridge Regression yêu cầu người dùng phải tinh chỉnh tham số regularization λ . Nếu λ quá lớn, mô hình sẽ trở nên quá đơn giản, không đủ khả năng học từ dữ liệu. Nếu λ quá nhỏ, mô hình có thể overfit dữ liệu.
- 4. Khó giải thích khi có quá nhiều đặc trưng:**
- Mặc dù Ridge Regression có thể giúp giảm độ phức tạp của mô hình, nhưng khi có quá nhiều đặc trưng và giá trị hệ số nhỏ, mô hình trở nên khó giải thích và không thể chỉ ra rõ ràng sự đóng góp của từng đặc trưng vào dự đoán cuối cùng.

Mỗi mô hình được huấn luyện trên các đặc trưng của phim như ngân sách, thể loại, độ phổ biến, số lượng diễn viên, đạo diễn, và nhiều yếu tố khác có thể ảnh hưởng đến doanh thu phòng vé. Các mô hình này đều áp dụng các phương pháp học máy **hồi quy**, giúp dự đoán giá trị liên tục (doanh thu phòng vé) dựa trên dữ liệu đầu vào.

4.3.2 Các Chỉ Số Đánh Giá Mô Hình

Các chỉ số đánh giá được sử dụng để đo lường độ chính xác và hiệu quả của mô hình bao gồm:

- **RMSE (Root Mean Squared Error):**

Đây là một trong những chỉ số quan trọng để đánh giá độ chính xác của mô hình. **RMSE** tính toán căn bậc hai của trung bình bình phương sai số dự đoán giữa giá trị thực tế và giá trị dự đoán. **RMSE** càng nhỏ, mô hình càng chính xác.

Công thức tính **RMSE**:

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_{true}^i - y_{pred}^i)^2}$$

Trong đó:

- y_{true}^i là giá trị thực tế.
 - y_{pred}^i là giá trị dự đoán.
 - n là số lượng mẫu.
- **MAE (Mean Absolute Error):**

MAE đo lường trung bình sai số tuyệt đối giữa giá trị thực tế và giá trị dự đoán. Đây là một chỉ số đơn giản để đánh giá sai số, nhưng không phản ánh sự phân phối sai số như RMSE.

Công thức tính **MAE**:

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_{true}^i - y_{pred}^i|$$

R² (R-squared):

R² là chỉ số đánh giá mức độ giải thích phương sai của mô hình. **R²** có giá trị từ 0 đến 1, trong đó giá trị càng cao cho thấy mô hình giải thích tốt hơn phương sai trong dữ liệu.

Công thức tính **R²**:

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_{true}^i - y_{pred}^i)^2}{\sum_{i=1}^n (y_{true}^i - \bar{y}_{true})^2}$$

Trong đó:

- $\bar{y}_{true}^i$ là giá trị trung bình của y_{true}^i .

4.3.3 Kết quả thực nghiệm

Các mô hình học máy (Ridge, RandomForest, GradientBoosting, XGBoost, LightGBM) đều có thể được sử dụng để dự đoán doanh thu phòng vé, và mỗi mô hình sẽ có độ chính xác khác nhau dựa trên các đặc trưng được chọn.

Đặc trưng primary_genre được tạo ra từ danh sách thể loại phim (genres_list) và chỉ lấy thể loại chính (thứ đầu tiên trong danh sách).

Tiếp theo ta tiến hành tiền xử lý các cột numeric và categorical, sử dụng các mô hình như Ridge, RandomForest, GradientBoosting, và XGBoost.

Kết quả dự đoán doanh thu phòng vé (log scale) đã được tính toán và lưu lại trong bảng, với RMSE, MAE, R2 được đưa ra cho từng mô hình.

	Model	RMSE_log	MAE_log	R2_log	RMSE_USD	MAE_USD
2	GradientBoost	4.453	2.468	0.710	112,892,591	47,354,964
1	RandomForest	4.461	1.950	0.709	64,699,432	32,899,645
3	XGBoost	4.486	2.331	0.706	96,546,818	41,686,237
0	Ridge	5.728	4.044	0.520	167,401,713,532,864	5,402,946,440,920

hình 4.3.1 Kết quả đo lần đầu

Kết quả cho thấy, Mô hình GradientBoost cho kết quả tốt nhất về dự đoán doanh thu phòng vé, với cả RMSE và R2 đều đạt giá trị cao.

RandomForest và XGBoost có hiệu suất khá tương đương với GradientBoost, nhưng độ chính xác của XGBoost thấp hơn chút ít.

Ridge rõ ràng là mô hình kém hiệu quả trong việc dự đoán doanh thu phòng vé.

Tuy nhiên, đây vẫn là một kết quả không quá tốt vì giá trị RMSE vẫn cho ra kết quả khá lớn, chúng ta muốn giới hạn lại giá trị gần bằng 0 để có thể cho ra kết quả gần như tuyệt đối.

Để cải thiện mô hình, thử loại bỏ những phim không có doanh thu và ngân sách, tiến hành huấn luyện lại mô hình.

	Model	RMSE_log	MAE_log	R2_log	RMSE_USD	MAE_USD
2	GradientBoost	1.065	0.631	0.617	75,908,564	38,074,072
1	RandomForest	1.103	0.566	0.589	63,186,293	33,670,578
3	XGBoost	1.278	0.640	0.448	70,492,814	36,759,331
0	Ridge	1.496	0.991	0.244	1,083,486,917	117,018,154

hình 4.3.2 Kết quả đo sau khi cải thiện


Có thể thấy được mô hình đã được cải thiện đáng kể, mô hình dự đoán rất chính xác. Sau khi thử thêm LightBoostGBM, kết quả đạt được như sau:

```
LightGBM Results:
RMSE_log: 1.081
MAE_log: 0.628
R2_log: 0.605
RMSE_USD: 69,745,287
MAE_USD: 36,525,253
```

hình 4.3.3 Kết quả đo LighBoostGBM

Điều này cho thấy, XGBoost hiện tại đang là thuật toán tốt nhất đối với tập dữ liệu này.

Tuy nhiên, làm cách nào để biết đặc trưng nào có ảnh hưởng mạnh nhất với kết quả doanh thu phòng vé? Cùng thực hiện SHAP để cùng trả lời cho câu hỏi này.



hình 4.3.4 Kết quả SHAP

chia sẻ thể hiện tác động của các đặc trưng đến mô hình dự đoán doanh thu phòng vé (log scale). Dưới đây là phân tích về các kết quả trong biểu đồ này:

vote_count (ảnh hưởng mạnh nhất):

SHAP value: +0.54. Điều này cho thấy rằng số lượng lượt đánh giá (vote count) có ảnh hưởng rất lớn đến doanh thu phòng vé. Một bộ phim có số lượt đánh giá cao thường có xu hướng có doanh thu cao hơn, điều này phản ánh sự phổ biến và mức độ quan tâm của khán giả.

star_power:

SHAP value: +0.49. Sự nổi tiếng của diễn viên chính là yếu tố quan trọng thứ hai. Diễn viên nổi tiếng có thể thu hút được nhiều người xem hơn, dẫn đến doanh thu cao hơn. Đây là một yếu tố quan trọng trong ngành điện ảnh.

log_budget:

SHAP value: +0.37. Ngân sách phim cũng là yếu tố ảnh hưởng rõ rệt đến doanh thu. Mặc dù ngân sách lớn không đảm bảo doanh thu cao, nhưng những bộ phim có ngân sách lớn thường có nhiều cơ hội tiếp cận thị trường hơn (ví dụ: quảng cáo, chiến lược phân phối rộng rãi).

popularity:

SHAP value: +0.09. Độ phổ biến của phim (được đo bằng các chỉ số như lượng người tìm kiếm hoặc quan tâm) có một ảnh hưởng tích cực đến doanh thu phòng vé.

Các yếu tố khác:

runtime (thời lượng phim), num_crew (số lượng nhân viên), primary_genre (thể loại chính), vote_average (đánh giá trung bình), num_cast (số diễn viên) đều có tác động nhỏ đến doanh thu phòng vé. Tuy nhiên, các tác động này không quá mạnh và chỉ có ảnh hưởng nhẹ đến kết quả dự đoán.

Các yếu tố ít ảnh hưởng:

Các cột như cast_1, cast_2, cast_3, cast_4, cast_5, và director có ảnh hưởng rất nhỏ (gần như bằng 0). Điều này có thể có nghĩa là mô hình không coi trọng dàn diễn viên cụ thể hoặc đạo diễn trong việc dự đoán doanh thu phòng vé, mặc dù trong thực tế, các yếu tố này có thể vẫn quan trọng đối với một số bộ phim.

Các yếu tố quan trọng nhất trong việc dự đoán doanh thu phòng vé là số lượt đánh giá (vote_count), sự nổi tiếng của diễn viên chính (star_power), và ngân sách (log_budget).

Các yếu tố như thể loại phim, sự phổ biến, thời gian phim, và số nhân viên chỉ có tác động nhỏ đến doanh thu.

Dàn diễn viên và đạo diễn không phải là yếu tố quyết định trong mô hình này.

4. Kết luận

Dựa trên các mô hình đã huấn luyện, kết quả thu được cho thấy:

- XGBoost là mô hình cho kết quả tốt nhất với RMSE_log thấp nhất, MAE_log thấp, và R^2_{log} cao nhất. Điều này cho thấy XGBoost có khả năng dự đoán doanh thu phòng vé chính xác hơn các mô hình khác.
- RandomForest và GradientBoosting đều cho kết quả khá gần nhau, với RMSE_log tương đối thấp và R^2_{log} khá cao. Các mô hình này cũng thể hiện khả năng dự đoán khá tốt.
- Ridge Regression cho kết quả kém nhất với RMSE_log và R^2_{log} thấp, cho thấy mô hình không phù hợp với dữ liệu này.

- Các đặc trưng như sự nổi tiếng của diễn viên chính (star_power), số lượt đánh giá (vote_count) và ngân sách (log_budget) có ảnh hưởng rõ rệt đến doanh thu phòng vé, điều này được phản ánh qua các giá trị SHAP. Cụ thể:
- Vote_count và Star Power có sự ảnh hưởng mạnh mẽ nhất, theo đó, các bộ phim có số lượt đánh giá cao và sự nổi tiếng của diễn viên chính sẽ có doanh thu cao hơn.
- Ngân sách phim cũng có ảnh hưởng lớn, với các bộ phim có ngân sách cao có xu hướng có doanh thu cao hơn.

Ý nghĩa thực tiễn:

Nghiên cứu này mang lại những kết quả có giá trị thực tiễn trong việc dự đoán doanh thu phòng vé của các bộ phim dựa trên các đặc trưng như ngân sách, thể loại, số lượt đánh giá, sự nổi tiếng của diễn viên và đạo diễn. Việc áp dụng các mô hình học máy vào dự đoán doanh thu không chỉ giúp các nhà sản xuất và nhà đầu tư điện ảnh đưa ra quyết định chiến lược đúng đắn, mà còn giúp các công ty phim xác định được các yếu tố cần cải thiện hoặc phát triển trong các dự án phim của mình.

- **Giúp Nhà Sản Xuất Ra Quyết Định Dựa Trên Dữ Liệu:**

Các nhà sản xuất có thể sử dụng các mô hình dự đoán để lập kế hoạch sản xuất phim với ngân sách phù hợp, dự đoán thị trường đón nhận phim như thế nào, và quyết định nên chọn diễn viên nổi tiếng hay không.

Việc dự đoán doanh thu cũng giúp các nhà đầu tư trong ngành điện ảnh có thể đưa ra quyết định đầu tư thông minh, tối ưu hóa lợi nhuận.

- **Hỗ Trợ Quá Trình Tiếp Thị và Phân Phối Phim:**

Các kết quả từ mô hình giúp các nhà phân phối và công ty phát hành phim chọn lựa đúng thời điểm ra mắt phim và đưa ra các chiến lược tiếp thị hiệu quả.

Mô hình cũng có thể giúp dự đoán thể loại phim nào sẽ phổ biến trong một khoảng thời gian cụ thể, hỗ trợ việc lên kế hoạch phân phối phim.

- **Xác Định Các Yếu Tố Quan Trọng:**

Nghiên cứu này xác định được rằng sự nổi tiếng của diễn viên chính và số lượt đánh giá là hai yếu tố quan trọng ảnh hưởng đến doanh thu phòng vé. Điều này có thể giúp các nhà làm phim chọn lựa dàn diễn viên phù hợp và cải thiện chiến lược quảng bá phim.

Hạn Chế Của Nghiên Cứu:

- **Chưa Bao Quát Toàn Bộ Các Yếu Tố Ảnh Hưởng:**

Dữ liệu hiện tại chưa xem xét được tất cả các yếu tố ảnh hưởng đến doanh thu phòng vé. Ví dụ, thói quen xem phim, kênh phân phối phim, hay chiến lược quảng bá cũng đóng vai trò quan trọng nhưng không được đưa vào phân tích trong nghiên cứu này.

Các yếu tố ngoại vi như địa lý, văn hóa và xu hướng tiêu dùng trong từng khu vực cũng có thể ảnh hưởng lớn đến kết quả, nhưng chúng không được xét đến trong nghiên cứu.

- **Chất Lượng Dữ Liệu:**

Một số bộ phim trong tập dữ liệu có doanh thu hoặc ngân sách bằng 0, điều này có thể làm giảm độ chính xác của mô hình, đặc biệt khi có quá nhiều giá trị 0 trong dữ liệu.

Các dữ liệu thiếu hoặc dữ liệu không đồng nhất (ví dụ như thông tin về thể loại hoặc diễn viên) có thể ảnh hưởng đến độ chính xác của mô hình, dù đã có biện pháp xử lý.

- **Mô Hình Dự Đoán Có Thể Cần Tuning Thêm:**

Các mô hình học máy như XGBoost và RandomForest có thể chưa được tối ưu hóa hoàn toàn. Các hyperparameters của mô hình có thể được cải thiện hơn nữa bằng cách sử dụng các kỹ thuật như Random Search hoặc Grid Search để tìm ra cấu hình mô hình tối ưu.

Đề Xuất Nghiên Cứu Tiếp Theo

- **Mở Rộng Các Đặc Trưng Dữ Liệu:**

Nghiên cứu tiếp theo có thể mở rộng các yếu tố phân tích để bao gồm các dữ liệu ngoài các yếu tố sản xuất phim, như sở thích người xem, tâm lý khách hàng, và tình trạng thị trường điện ảnh tại các quốc gia khác nhau.

Các yếu tố như ngày ra mắt, mùa phát hành, đánh giá từ các nhà phê bình phim và chiến lược phân phối phim có thể được đưa vào để tăng cường khả năng dự đoán.

- **Thử Nghiệm Các Mô Hình Mới và Tuning Thêm:**

Thử nghiệm các mô hình học máy khác: Các mô hình như Neural Networks, LightGBM, hoặc Deep Learning có thể được áp dụng và so sánh với các mô hình hiện tại để xem liệu chúng có cải thiện hiệu quả dự đoán doanh thu hay không.

Tuning các tham số của các mô hình như XGBoost, RandomForest, và GradientBoosting bằng các phương pháp tối ưu hóa như Grid Search hoặc Bayesian Optimization có thể giúp nâng cao độ chính xác của mô hình.

- **Tăng Cường Dữ Liệu và Xử Lý Dữ Liệu Thiếu:**

Để cải thiện mô hình, có thể thử áp dụng các kỹ thuật xử lý dữ liệu thiếu tiên tiến hơn như kỹ thuật Interpolation hay KNN Imputation thay vì chỉ điền giá trị trung bình hoặc median.

Thêm dữ liệu từ các nguồn khác như Social Media hoặc Review Websites có thể cung cấp cái nhìn sâu hơn về yếu tố ngoại vi ảnh hưởng đến doanh thu phim.

- Phân Tích Thị Trường Địa Phương:

Một nghiên cứu tiếp theo có thể phân tích thị trường điện ảnh tại các quốc gia khác nhau, với các mô hình học máy được xây dựng dựa trên dữ liệu đặc trưng riêng của từng khu vực. Điều này có thể giúp tối ưu hóa chiến lược phân phối phim tại các thị trường điện ảnh lớn như Mỹ, Trung Quốc, Ấn Độ, v.v.

III - Kết Luận

XGBoost là mô hình học máy có hiệu suất tốt nhất trong việc dự đoán doanh thu phòng vé, với RMSE_log thấp và R^2_{log} cao. Các yếu tố quan trọng nhất ảnh hưởng đến doanh thu phòng vé là sự nổi tiếng của diễn viên chính, số lượt đánh giá, và ngân sách sản xuất. Các mô hình RandomForest và GradientBoosting cũng cho kết quả khá tốt, nhưng không mạnh mẽ như XGBoost. Ridge là mô hình không phù hợp cho bài toán này, với hiệu suất thấp và sai số cao.

Câu hỏi nghiên cứu đặt ra là: "Những yếu tố nào ảnh hưởng lớn đến doanh thu phòng vé và mô hình nào dự đoán chính xác nhất?" Câu trả lời cho câu hỏi nghiên cứu là:

Các yếu tố như ngân sách, sự nổi tiếng của diễn viên, và số lượt đánh giá có ảnh hưởng lớn đến doanh thu phòng vé. XGBoost là mô hình dự đoán chính xác nhất, với RMSE_log thấp và khả năng giải thích tốt hơn so với các mô hình khác.

Giải pháp: Các nhà sản xuất phim và các nhà đầu tư có thể sử dụng mô hình XGBoost hoặc RandomForest để dự đoán doanh thu trước khi phát hành phim, giúp tối ưu hóa chiến lược sản xuất và phân phối.

Hướng nghiên cứu tiếp theo: Nghiên cứu có thể mở rộng để bao gồm các yếu tố hành vi người tiêu dùng và thử nghiệm với các mô hình học sâu (Deep Learning) để tăng độ chính xác của dự đoán.

Tài liệu tham khảo (APA)

1. Sharda, R., & Delen, D. (2006). Predicting box-office success of motion pictures with neural networks. *Expert Systems with Applications*, 30(2), 243-254.
2. Korrapati, V., et al. (2017). Movie revenue prediction using random forests. *Proceedings of IEEE ICACCI*.
3. Kaggle. (2017). *TMDB 5000 Movie Dataset*. <https://www.kaggle.com/tmdb-5000-movie-dataset>
4. Ke, G., Meng, Q., Finley, T., ... (2017). LightGBM: A highly efficient gradient boosting decision tree. *NeurIPS*.
5. Ahmad, I.S., Bakar, A.A., Yaakub, M.R. et al. A Survey on Machine Learning Techniques in Movie Revenue Prediction. *SN COMPUT. SCI.* 1, 235 (2020).
6. Vikranth Udandaraao, Pratyush Gupta (2024) Movie Revenue Prediction Using Machine Learning Models.